Komputerowe systemy rozpoznawania
2024/2025
Projekt 1. Klasyfikacja dokumentów tekstowych

Bartosz Kołaciński, 251554
Jakub Rosiak, 251620
Prowadzący: dr. inż. Marcin Kacprowicz

30 marca 2026

1 Cel projektu

Celem niniejszego projektu jest implementacja, analiza oraz optymalizacja algorytmu k-najbliższych sąsiadów przeznaczonego do kategoryzacji dokumentów tekstowych na podstawie wyekstrahowanych cech o charakterze liczbowym i tekstowym. Klasyfikacja prowadzona jest na zbiorze *Reuters-21578* [3], a zadanie polega na przyporządkowaniu artykułów do jednej z 6 klas reprezentujących kraje (USA, UK, Francja, Kanada, Japonia, Niemcy Zachodnie). Model uwzględnia zjawisko braku zbalansowania danych (znaczna przewaga artykułów z USA) poprzez zbalansowany podział zbioru na część treningową oraz testową (w proporcji 80/20) i obejmuje zbadanie skuteczności za pomocą metryk Accuracy oraz F1.

2 Klasyfikacja nadzorowana metodą k-NN. Ekstrakcja cech, wektory cech

2.1 Opis metody k-NN w zadaniu kategoryzacji dokumentów

Algorytm k-najbliższych sąsiadów (k-NN) to nadzorowana metoda klasyfikacji z grupy metod minimalnoodległościowych [1], polegająca na przypisaniu nowego obiektu do klasy, która najczęściej występuje wśród jego k najbliższych obiektów ze zbioru uczącego (treningowego). W tym zadaniu, każdy dokument jest przekształcany w wielowymiarowy wektor wyekstrahowanych cech. Odległość pomiędzy wektorami (dokumentami) obliczana jest na podstawie zdefiniowanej metryki (Euklidesowej dla cech liczbowych i 0/1 dla cech tekstowych). Algorytm przyjmuje jako parametry wejściowe zbiór tekstów, zestaw wag dla każdej z cech

oraz liczbę k, a na wyjściu zwraca najbardziej prawdopodobną klasę docelową (kraj, do którego przypisany jest tekst).

2.2 Ekstrakcja i opis cech wektora

Dokumenty reprezentowane są za pomocą zbioru zdefiniowanych cech tekstowych i liczbowych, wyekstrahowanych osobno dla każdego danego artykułu. Niech $D = (d_1, d_2, ..., d_L)$ oznacza zbiór znaków występujących w artykule o długości L, a $W = (w_1, w_2, ..., w_N)$ to zbiór N słów w danym artykule (wyekstrahowanych za pomocą wyrażeń regularnych). Wprowadźmy funkcję pomocniczą $h(c)$, która przyjmuje wartość 1, gdy warunek c jest spełniony, oraz 0 w przeciwnym wypadku.

Cechy liczbowe:

1. **CharCountSpec (c_1):** Ilość wszystkich znaków w dokumencie bez spacji.

$$c_1 = \sum_{j=1}^{L} h(d_j \neq \text{' '}) \tag{1}$$

Zakres wartości: $\mathbb{N}$

2. **WordCountSpec (c_2):** Ilość wszystkich słów w danym tekście. Słowo jest zdefiniowane jako zbiór znaków oddzielonych spacją.

$$c_2 = N = \sum_{j=1}^{N} 1 \tag{2}$$

Zakres wartości: $\mathbb{N}$.

3. **AverageWordLengthSpec (c_3):** Średnia długość słowa.

$$c_3 = \frac{1}{N} \sum_{j=1}^{N} |w_j| \tag{3}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$. (Gdy brak słów, cecha równa 0).

4. **LexicalDiversitySpec (c_4):** Stosunek ilości unikalnych słów do wszystkich słów w dokumencie. Im większy wynik, tym większy zasób słownictwa w danym tekście. Unikalne słowa badane są bez względu na wielkość znaków. Niech U będzie zbiorem unikalnych słów z W zredukowanych do małych liter.

$$c_4 = \frac{|U|}{N} \tag{4}$$

Zakres wartości: $[0, 1]$.

5. **LongWordToOtherWordsRatioSpec (c_5):** Stosunek liczby słów długich (co najmniej 5 liter) do liczby pozostałych słów. Niech $L_w = \sum_{j=1}^{N} h(|w_j| \geq 5)$.

$$c_5 = \begin{cases} \frac{L_w}{N - L_w} & \text{dla } N - L_w > 0 \\ L_w & \text{dla } N - L_w <= 0 \end{cases} \tag{5}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

6. **ProperNounRatioSpec (c_6):** Współczynnik nazewnictwa własnego – stosunek wyrazów rozpoczynających się wielką literą (z pominięciem tych po znaku końca zdania) do całkowitej ilości słów. Niech $P = \sum_{j=1}^{N} h(w_j)$ jest nazwą własną).

$$c_6 = \frac{P}{N} \tag{6}$$

Zakres wartości: $[0, 1]$.

7. **UpperToAllCharsRatioSpec (c_7):** Stosunek wielkich liter do całkowitej długości tekstu.

$$c_7 = \frac{1}{L} \sum_{i=1}^{L} h(d_i \in \text{Wielkie Litery}) \tag{7}$$

Zakres wartości: $[0, 1]$.

8. **UpperToLowerRatioSpec (c_8):** Stosunek ilości wielkich liter do małych liter. Niech $U_c = \sum_{i=1}^{L} h(d_i \in$ Wielkie Litery oraz $M_c = \sum_{i=1}^{L} h(d_i \in$ Małe Litery)

$$c_8 = \begin{cases} \frac{U_c}{M_c} & \text{dla } M_c > 0 \\ U_c & \text{w p. p.} \end{cases} \tag{8}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

9. **AlnumToOtherCharsRatioSpec (c_9):** Stosunek liczby znaków alfanumerycznych (litery i cyfry) do liczby pozostałych znaków (interpunkcja, znaki białe, znaki specjalne). Niech $A_c = \sum_{i=1}^{L} h(d_i \in Alfanumeryczne)$.

$$c_9 = \begin{cases} \frac{A_c}{L - A_c} & \text{dla } L - A_c > 0 \\ A_c & \text{dla } L - A_c <= 0 \end{cases} \tag{9}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

Cechy tekstowe:

10. **ProperNounSpec (t_1):** Pierwszą napotkana w tekście nazwa własna (wyraz zaczynający się wielką literą, niebędący częścią zdania). Jeśli takiej nie ma, przyjmuje wartość tekstową "None".

$$t_1 = w_j, \quad \text{gdzie } j = \min\{i : h(w_i \text{ jest nazwą własną}) = 1\} \tag{10}$$

Przyjmuje wartość "None"jeśli w tekście nie ma nazw własnych Zakres wartości: Ciąg znaków (String).

11. **RarestRepeatedWordSpec (t_2):** Wyraz o najmniejszej ilości powtórzeń, jednak pojawiający się przynajmniej dwukrotnie w artykule (redukcja do małych liter). W przypadku remisów wybierane jest słowo pierwsze po sortowaniu alfabetycznie. Jeśli takiego wyrazu nie ma, przyjmuje wartość tekstową "None". Niech $C(w)$ to liczba wystąpień słowa $u \in U$ w tekście, a $S = \{u \in U : C(u) \geq 2\}$ zbiór słów powtarzających się.

$$t_2 = u \in S : C(u) = \min_{v \in S} C(v) \tag{11}$$

Zakres wartości: Ciąg znaków (String).

Postać wektora cech:

Na podstawie zaprezentowanych specyfikacji każdy tekst zostaje przekształcony na wektor V postaci:

$$V = [c_1, c_2, c_3, c_4, c_5, c_6, c_7, c_8, c_9, t_1, t_2] \tag{12}$$

Przykład wektora dla zdania „ALFA alfa 123 !!! kot kot Dom dom DOM”:

$$V_{przyklad} = [30.0, 8.0, 3.25, 0.5, 0.0, 0.0, 0.25, 0.6, 1.4, \text{"ALFA"}, \text{"alfa"}] \tag{13}$$

3 Miary jakości klasyfikacji

W celu oceny skuteczności algorytmu k-NN zastosowano zestaw miar jakości klasyfikacji pozwalających ocenę w skali wszystkich klas, jak i dla pojedynczych krajów. Kluczowe jest rozróżnienie między ogólną dokładnością algorytmu a jego umiejętnością w poprawnym rozpoznawaniu klas rzadkich [1].

3.1 Parametry i oznaczenia

Dla każdej z klas (krajów) $i \in \{\text{west-germany, usa, france, uk, canada, japan}\}$ definiujemy następujące parametry:

- TP_i - liczba dokumentów poprawnie przypisanych do klasy i.
- $actual_i$ - całkowita liczba dokumentów faktycznie należących do klasy i w zbiorze testowym.
- $predicted_i$ - całkowita liczba dokumentów, które algorytm zaklasyfikował do klasy i.

3.2 Metryki cząstkowe per klasa

Dla każdej klasy obliczane są trzy miary, które przyjmują wartości z zakresu $[0, 1]$, gdzie 1 oznacza wynik idealny:

1. **Precision** P_i: Określa, jakie jest prawdopodobieństwo, że dokument zaklasyfikowany do danego kraju faktycznie z niego pochodzi.

$$P_i = \begin{cases} \frac{TP_i}{Predicted_i} & \text{dla } Predicted_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{14}$$

2. **Recall** R_i: Określa, jaką część wszystkich artykułów z danego kraju udało się poprawnie wykryć algorytmowi.

$$R_i = \begin{cases} \frac{TP_i}{Actual_i} & \text{dla } Actual_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{15}$$

3. **F1-score** ($F1_i$): Średnia harmoniczna precyzji i pełności..

$$F1_i = \begin{cases} \frac{2 \cdot P_i \cdot R_i}{P_i + R_i} & \text{dla } P_i + R_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{16}$$

3.3 Metryki globalne

Do globalnej oceny modelu zastosowano:

1. **Accuracy** Acc: Stosunek wszystkich poprawnych klasyfikacji do liczby wszystkich dokumentów M.

$$Acc = \frac{\sum_{i=1}^{6} TP_i}{M} \tag{17}$$

2. **Macro-F1**: Średnia arytmetyczna wartości F1 dla wszystkich klas.

$$MacroF1 = \frac{1}{6} \sum_{i=1}^{6} F1_i \tag{18}$$

3.4 Wyniki i ich interpretacja

Przykładowe wartości z przeprowadzonego testu ($k = 5$ oraz stosunek danych treningowych do testowych $80 : 20$):

Klasa / Metryka	**Precision** (P_i)	**Recall** (R_i)	**F1-score** ($F1_i$)
usa	82,75%	94,81%	88,37%
canada	53,06%	15,29%	23,74%
japan	34,38%	22,00%	26,83%

Metryka globalna	**Nazwa**	**Wartość**
Accuracy (Acc)	Ogólna dokładność modelu	**78,91%**
Macro-F1	Średnia harmoniczna klas	**34,55%**

Tabela 1: Zestawienie przykładowych miar jakości klasyfikacji dla $k = 5$.

Algorytm osiągnął dokładność bliską 79%, jednak łatwo zauważyć niskie wartości metryk dla krajów innych niż USA, wynika to z znacznej przewagi USA w danych. Metryk Macro-F1 znacznie lepiej odzwierciedla słabości modelu w rozpoznawaniu innych klas.

4 Metryki i miary podobieństwa tekstów w klasyfikacji

Ważną częścią metody k-NN jest wybór metryk i miar do obliczania odległości między dwoma danymi wektorami cech. Aby zapobiec dominacji cech, które mogą przyjmować duże wartości (np. liczba znaków w danym tekście) stosujemy normalizacje min-max do przedziału $[0; 1]$ na podstawie granicznych wartości znajdujących się w zbiorze testowym. Niech n będzie oznaczeniem funkcji wykorzystanej do normalizacji.

Niech V^a i V^b będą dwoma wektorami cech, a w_i wagą przypisaną do i-tej cechy. Dla cech liczbowych odległość dla i-tej cechy liczbowej określamy następująco:

$$\delta_i(V^a, V^b) = |n(V_i^a) - n(V_i^b)| \tag{19}$$

Dla i-tej cechy tekstowej wartość składowej odległości obliczamy za pomocą:

$$\delta_i(V^a, V^b) = d_J(V_i^a, V_i^b) \tag{20}$$

gdzie d_J to odległość Jaccarda oparta na n-gramach.

4.1 Miara podobieństwa tekstów - n-gramy

W celu obliczenia odległości między cechami tekstowymi zastosowano metodę bazującą na zbiorach n-gramów dla $n = 2$. Niech s będzie dowolnym ciągiem znaków, a $G_n(s)$ to zbiór wszystkich podciągów o długości n z tekstu s. Dla $s =$ `'ALFA'`: $G_2($`'ALFA'`$) = \{$`'AL', 'LF', 'FA'`$\}$.

Podobieństwo Jaccarda (J) dwóch tekstów (t_a i t_b) definiujemy jako stosunek mocy części wspólnej zbiorów ich bigramów do mocy ich sumy:

$$J(t_a, t_b) = \frac{|G_2(t_a) \cap G_2(t_b)|}{|G_2(t_a) \cup G_2(t_b)|} \tag{21}$$

Ostateczna miara odległości jest opisana za pomocą wzoru:

$$d_J(t_a, t_b) = 1 - J(t_a, t_b) \tag{22}$$

Dla dwóch identycznych tekstów t_a i t_b $J(t_a, t_b)$ przyjmuje wartość 1, więc odległość wynosi 1.

4.2 Zastosowane metryki

Na podstawie obliczonych odległości δ_i oraz wag w_i, odległość całkowitą $D(V^a, V^b)$ oblicza się przy użyciu jednej z metryk:

4.2.1 Metryka Euklidesowa

$$D(V^a, V^b) = \sqrt{\sum_{i=1}^{i=11} (w_i \cdot \delta_i)^2} \tag{23}$$

4.2.2 Metryka Manhattan (uliczna)

$$D(V^a, V^b) = \sum_{i=1}^{i=11} w_i \cdot \delta_i \tag{24}$$

4.2.3 Metryka Czebyszewa

$$D(V^a, V^b) = \max_i (w_i \cdot \delta_i) \tag{25}$$

4.3 Obliczanie przykładowych wartości

Rozważmy dwa proste wektory cech V^1 i V^2 (z cechami c_1, c_2, c_3) z wagami równymi 1:

- $V^1 = [0.6, 0.7, \texttt{'LONDON'}]$
- $V^2 = [0.4, 0.8, \texttt{'LONDONER'}]$

Obliczenia składowe:

- $\delta_1 = |0.6 - 0.4| = 0.2$
- $\delta_2 = |0.7 - 0.8| = 0.1$
- $G(c_3^1) = \{LO, ON, ND, DO, ON\} \rightarrow \{LO, ON, ND, DO\}$
- $G(c_3^2) = \{LO, ON, ND, DO, ON, NE, ER\} \rightarrow \{LO, ON, ND, DO, NE, ER\}$
- $J = \frac{|\{LO,ON,ND,DO\}|}{|\{LO,ON,ND,DO,NE,ER\}|} = \frac{2}{3} \approx 0.67$
- $\delta_3 = 1 - 0.67 = 0.33$

Wyniki dla różnych metryk:

- $D_{euklides} = \sqrt{0.2^2 + 0.1^2 + 0.33^2} \approx 0.4$
- $D_{manhattan} = 0.2 + 0.1 + 0.33 = 0.53$
- $D_{czebyszew} = \max(0.1, 0.2, 0.33) = 0.33$

5 Wyniki klasyfikacji dla różnych parametrów wejściowych

Wstępne wyniki miary Accuracy dla próbnych klasyfikacji na ograniczonym zbiorze tekstów (podać parametry i kryteria wyboru wg punktów 3.-8. z opisu Projektu 1.). **Sekcja uzupełniona jako efekt zadania Tydzień 05 wg Harmonogramu Zajęć na WIKAMP KSR.**

6 Dyskusja, wnioski, sprawozdanie końcowe

We wnioskach z badania skomentować wyłącznie wpływ parametrów i cech na jakość procesu klasyfikacji. Innymi słowy – wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury. Znaczenie kolejnych eksperymentów wg punktów 2.-8. opisu projektu 1. Każdorazowo podane parametry, dla których przeprowadzana eksperyment. Wykresy (np. słupkowe) i tabele wyników obowiązkowe, dokładnie opisane w „captions" (tytułach), konieczny opis osi i jednostek wykresów oraz kolumn i wierszy tabel.

Ewentualne wyniki realizacji punktu 9. opisu Projektu 1., czyli „na ocenę 5.0" i ich porównanie do wyników z części obowiązkowej.Dokładne interpretacje uzyskanych wyników w zależności od parametrów klasyfikacji opisanych w punktach 3.-8 opisu Projektu 1. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: wykresów, tabel).
Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje poziom zrozumienia rozwiązywanego problemu.

** Możliwości kontynuacji prac w obszarze systemów rozpoznawania, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadań Tydzień 05 i Tydzień 06 wg Harmonogramu Zajęć na WIKAMP KSR.

7 Braki w realizacji projektu 1.

Wymienić wg opisu Projektu 1. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

[1] R. Tadeusiewicz: Rozpoznawanie obrazów, PWN, Warszawa, 1991.

[2] A. Niewiadomski, Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2008.

[3] David Lewis, *Reuters-21578 Text Categorization Collection*, UCI Machine Learning Repository, 1997. Dostępne online: `https://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection`