Komputerowe systemy rozpoznawania
2024/2025
Projekt 1. Klasyfikacja dokumentów tekstowych

Bartosz Kołaciński, 251554
Jakub Rosiak, 251620
Prowadzący: dr. inż. Marcin Kacprowicz

13 kwietnia 2026

1 Cel projektu

Celem niniejszego projektu jest implementacja, analiza oraz optymalizacja algorytmu k-najbliższych sąsiadów przeznaczonego do kategoryzacji dokumentów tekstowych na podstawie wyekstrahowanych cech o charakterze liczbowym i tekstowym. Klasyfikacja prowadzona jest na zbiorze *Reuters-21578* [3], a zadanie polega na przyporządkowaniu artykułów do jednej z 6 klas reprezentujących kraje (USA, UK, Francja, Kanada, Japonia, Niemcy Zachodnie). Model uwzględnia zjawisko braku zbalansowania danych (znaczna przewaga artykułów z USA) poprzez zbalansowany podział zbioru na część treningową oraz testową (w proporcji 80/20) i obejmuje zbadanie skuteczności za pomocą metryk Accuracy oraz F1.

2 Klasyfikacja nadzorowana metodą k-NN. Ekstrakcja cech, wektory cech

2.1 Opis metody k-NN w zadaniu kategoryzacji dokumentów

Algorytm k-najbliższych sąsiadów (k-NN) to nadzorowana metoda klasyfikacji z grupy metod minimalnoodległościowych [1], polegająca na przypisaniu nowego obiektu do klasy, która najczęściej występuje wśród jego k najbliższych obiektów ze zbioru uczącego (treningowego). W tym zadaniu, każdy dokument jest przekształcany w wielowymiarowy wektor wyekstrahowanych cech. Odległość pomiędzy wektorami (dokumentami) obliczana jest na podstawie zdefiniowanej metryki (Euklidesowej dla cech liczbowych i 0/1 dla cech tekstowych). Algorytm przyjmuje jako parametry wejściowe zbiór tekstów, zestaw wag dla każdej z cech

oraz liczbę k, a na wyjściu zwraca najbardziej prawdopodobną klasę docelową (kraj, do którego przypisany jest tekst).

2.2 Ekstrakcja i opis cech wektora

Dokumenty reprezentowane są za pomocą zbioru zdefiniowanych cech tekstowych i liczbowych, wyekstrahowanych osobno dla każdego danego artykułu. Niech $D = (d_1, d_2, ..., d_L)$ oznacza zbiór znaków występujących w artykule o długości L, a $W = (w_1, w_2, ..., w_N)$ to zbiór N słów w danym artykule (wyekstrahowanych za pomocą wyrażeń regularnych). Wprowadźmy funkcję pomocniczą $h(c)$, która przyjmuje wartość 1, gdy warunek c jest spełniony, oraz 0 w przeciwnym wypadku.

Cechy liczbowe:

1. **CharCountSpec (c_1):** Ilość wszystkich znaków w dokumencie bez spacji.

$$c_1 = \sum_{j=1}^{L} h(d_j \neq \text{' '}) \tag{1}$$

Zakres wartości: $\mathbb{N}$

2. **WordCountSpec (c_2):** Ilość wszystkich słów w danym tekście. Słowo jest zdefiniowane jako zbiór znaków oddzielonych spacją.

$$c_2 = N = \sum_{j=1}^{N} 1 \tag{2}$$

Zakres wartości: $\mathbb{N}$.

3. **AverageWordLengthSpec (c_3):** Średnia długość słowa.

$$c_3 = \frac{1}{N} \sum_{j=1}^{N} |w_j| \tag{3}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$. (Gdy brak słów, cecha równa 0).

4. **LexicalDiversitySpec (c_4):** Stosunek ilości unikalnych słów do wszystkich słów w dokumencie. Im większy wynik, tym większy zasób słownictwa w danym tekście. Unikalne słowa badane są bez względu na wielkość znaków. Niech U będzie zbiorem unikalnych słów z W zredukowanych do małych liter.

$$c_4 = \frac{|U|}{N} \tag{4}$$

Zakres wartości: $[0, 1]$.

5. **LongWordToOtherWordsRatioSpec (c_5):** Stosunek liczby słów długich (co najmniej 5 liter) do liczby pozostałych słów. Niech $L_w = \sum_{j=1}^{N} h(|w_j| \geq 5)$.

$$c_5 = \begin{cases} \frac{L_w}{N - L_w} & \text{dla } N - L_w > 0 \\ L_w & \text{dla } N - L_w <= 0 \end{cases} \tag{5}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

6. **ProperNounRatioSpec (c_6):** Współczynnik nazewnictwa własnego – stosunek wyrazów rozpoczynających się wielką literą (z pominięciem tych po znaku końca zdania) do całkowitej ilości słów. Niech $P = \sum_{j=1}^{N} h(w_j)$ jest nazwą własną).

$$c_6 = \frac{P}{N} \tag{6}$$

Zakres wartości: $[0, 1]$.

7. **UpperToAllCharsRatioSpec (c_7):** Stosunek wielkich liter do całkowitej długości tekstu.

$$c_7 = \frac{1}{L} \sum_{i=1}^{L} h(d_i \in \text{Wielkie Litery}) \tag{7}$$

Zakres wartości: $[0, 1]$.

8. **UpperToLowerRatioSpec (c_8):** Stosunek ilości wielkich liter do małych liter. Niech $U_c = \sum_{i=1}^{L} h(d_i \in$ Wielkie Litery oraz $M_c = \sum_{i=1}^{L} h(d_i \in$ Małe Litery)

$$c_8 = \begin{cases} \frac{U_c}{M_c} & \text{dla } M_c > 0 \\ U_c & \text{w p. p.} \end{cases} \tag{8}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

9. **AlnumToOtherCharsRatioSpec (c_9):** Stosunek liczby znaków alfanumerycznych (litery i cyfry) do liczby pozostałych znaków (interpunkcja, znaki białe, znaki specjalne). Niech $A_c = \sum_{i=1}^{L} h(d_i \in Alfanumeryczne)$.

$$c_9 = \begin{cases} \frac{A_c}{L - A_c} & \text{dla } L - A_c > 0 \\ A_c & \text{dla } L - A_c <= 0 \end{cases} \tag{9}$$

Zakres wartości: $\mathbb{R}_+ \cup 0$.

Cechy tekstowe:

10. **ProperNounSpec (t_1):** Pierwszą napotkana w tekście nazwa własna (wyraz zaczynający się wielką literą, niebędący częścią zdania). Jeśli takiej nie ma, przyjmuje wartość tekstową "None".

$$t_1 = w_j, \quad \text{gdzie } j = \min\{i : h(w_i \text{ jest nazwą własną}) = 1\} \tag{10}$$

Przyjmuje wartość "None"jeśli w tekście nie ma nazw własnych Zakres wartości: Ciąg znaków (String).

11. **RarestRepeatedWordSpec (t_2):** Wyraz o najmniejszej ilości powtórzeń, jednak pojawiający się przynajmniej dwukrotnie w artykule (redukcja do małych liter). W przypadku remisów wybierane jest słowo pierwsze po sortowaniu alfabetycznie. Jeśli takiego wyrazu nie ma, przyjmuje wartość tekstową "None". Niech $C(w)$ to liczba wystąpień słowa $u \in U$ w tekście, a $S = \{u \in U : C(u) \geq 2\}$ zbiór słów powtarzających się.

$$t_2 = u \in S : C(u) = \min_{v \in S} C(v) \tag{11}$$

Zakres wartości: Ciąg znaków (String).

Postać wektora cech:

Na podstawie zaprezentowanych specyfikacji każdy tekst zostaje przekształcony na wektor V postaci:

$$V = [c_1, c_2, c_3, c_4, c_5, c_6, c_7, c_8, c_9, t_1, t_2] \tag{12}$$

Przykład wektora dla zdania „ALFA alfa 123 !!! kot kot Dom dom DOM”:

$$V_{przyklad} = [30.0, 8.0, 3.25, 0.5, 0.0, 0.0, 0.25, 0.6, 1.4, \text{"ALFA"}, \text{"alfa"}] \tag{13}$$

3 Miary jakości klasyfikacji

W celu oceny skuteczności algorytmu k-NN zastosowano zestaw miar jakości klasyfikacji pozwalających ocenę w skali wszystkich klas, jak i dla pojedynczych krajów. Kluczowe jest rozróżnienie między ogólną dokładnością algorytmu a jego umiejętnością w poprawnym rozpoznawaniu klas rzadkich [1].

3.1 Parametry i oznaczenia

Dla każdej z klas (krajów) $i \in \{\text{west-germany, usa, france, uk, canada, japan}\}$ definiujemy następujące parametry:

- TP_i - liczba dokumentów poprawnie przypisanych do klasy i.
- $actual_i$ - całkowita liczba dokumentów faktycznie należących do klasy i w zbiorze testowym.
- $predicted_i$ - całkowita liczba dokumentów, które algorytm zaklasyfikował do klasy i.

3.2 Miary cząstkowe per klasa

Dla każdej klasy obliczane są trzy miary, które przyjmują wartości z zakresu $[0, 1]$, gdzie 1 oznacza wynik idealny:

1. **Precision** P_i: Określa, jakie jest prawdopodobieństwo, że dokument zaklasyfikowany do danego kraju faktycznie z niego pochodzi.

$$P_i = \begin{cases} \frac{TP_i}{Predicted_i} & \text{dla } Predicted_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{14}$$

2. **Recall** R_i: Określa, jaką część wszystkich artykułów z danego kraju udało się poprawnie wykryć algorytmowi.

$$R_i = \begin{cases} \frac{TP_i}{Actual_i} & \text{dla } Actual_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{15}$$

3. **F1-score ($F1_i$)**: Średnia harmoniczna precyzji i pełności..

$$F1_i = \begin{cases} \frac{2 \cdot P_i \cdot R_i}{P_i + R_i} & \text{dla } P_i + R_i > 0 \\ 0 & \text{w p.p.} \end{cases} \tag{16}$$

3.3 Miary globalne

Do globalnej oceny modelu zastosowano:

1. **Accuracy**: Stosunek wszystkich poprawnych klasyfikacji do liczby wszystkich dokumentów M.

$$Acc = \frac{\sum_{i=1}^{6} TP_i}{M} \tag{17}$$

2. **Macro-F1**: Średnia arytmetyczna wartości F1 dla wszystkich klas.

$$MacroF1 = \frac{1}{6} \sum_{i=1}^{6} F1_i \tag{18}$$

3.4 Wyniki i ich interpretacja

Przykładowe wartości z przeprowadzonego testu ($k = 5$ oraz stosunek danych treningowych do testowych $80 : 20$):

Klasa (kraj)	**Precision (P_i)**	**Recall (R_i)**	**F1-score ($F1_i$)**
usa	82,75%	94,81%	88,37%
canada	53,06%	15,29%	23,74%
japan	34,38%	22,00%	26,83%

Miara globalna	**Nazwa**	**Wartość**
Accuracy (Acc)	Ogólna dokładność modelu	**78,91%**
Macro-F1	Średnia harmoniczna klas	**34,55%**

Tabela 1: Zestawienie przykładowych miar jakości klasyfikacji dla $k = 5$.

Algorytm osiągnął dokładność bliską 79%, jednak łatwo zauważyć niskie wartości miar dla krajów innych niż USA, wynika to z znacznej przewagi USA w danych. Macro-F1 znacznie lepiej odzwierciedla słabości modelu (jego niską stabilność) w rozpoznawaniu innych klas.

4 Metryki i miary podobieństwa tekstów w klasyfikacji

Ważną częścią metody k-NN jest wybór metryk i miar do obliczania odległości między dwoma danymi wektorami cech. Aby zapobiec dominacji cech, które mogą przyjmować duże wartości (np. liczba znaków w danym tekście) stosujemy normalizacje min-max do przedziału $[0; 1]$ na podstawie granicznych wartości znajdujących się w zbiorze testowym. Niech n będzie oznaczeniem funkcji wykorzystanej do normalizacji.

Niech V^a i V^b będą dwoma wektorami cech, a w_i wagą przypisaną do i-tej cechy. Dla cech liczbowych odległość dla i-tej cechy liczbowej określamy następująco:

$$\delta_i(V^a, V^b) = |n(V_i^a) - n(V_i^b)| \tag{19}$$

Dla i-tej cechy tekstowej wartość składowej odległości obliczamy za pomocą:

$$\delta_i(V^a, V^b) = d_J(V_i^a, V_i^b) \tag{20}$$

gdzie d_J to odległość Jaccarda oparta na n-gramach.

4.1 Miara podobieństwa tekstów - n-gramy

W celu obliczenia odległości między cechami tekstowymi zastosowano metodę bazującą na zbiorach n-gramów dla $n = 2$. Niech s będzie dowolnym ciągiem znaków, a $G_n(s)$ to zbiór wszystkich podciągów o długości n z tekstu s. Dla $s =$ `'ALFA'`: $G_2($`'ALFA'`$) = \{$`'AL', 'LF', 'FA'`$\}$.

Podobieństwo Jaccarda (J) dwóch tekstów (t_a i t_b) definiujemy jako stosunek mocy części wspólnej zbiorów ich bigramów do mocy ich sumy:

$$J(t_a, t_b) = \frac{|G_2(t_a) \cap G_2(t_b)|}{|G_2(t_a) \cup G_2(t_b)|} \tag{21}$$

Ostateczna miara odległości jest opisana za pomocą wzoru:

$$d_J(t_a, t_b) = 1 - J(t_a, t_b) \tag{22}$$

Dla dwóch identycznych tekstów t_a i t_b $J(t_a, t_b)$ przyjmuje wartość 1, więc odległość wynosi 1.

4.2 Zastosowane metryki

Na podstawie obliczonych odległości δ_i oraz wag w_i, odległość całkowitą $D(V^a, V^b)$ oblicza się przy użyciu jednej z metryk:

4.2.1 Metryka Euklidesowa

$$D(V^a, V^b) = \sqrt{\sum_{i=1}^{i=11} (w_i \cdot \delta_i)^2} \tag{23}$$

4.2.2 Metryka Manhattan (uliczna)

$$D(V^a, V^b) = \sum_{i=1}^{i=11} w_i \cdot \delta_i \tag{24}$$

4.2.3 Metryka Czebyszewa

$$D(V^a, V^b) = \max_i (w_i \cdot \delta_i) \tag{25}$$

4.3 Obliczanie przykładowych wartości

Rozważmy dwa proste wektory cech V^1 i V^2 (z cechami c_1, c_2, c_3) z wagami równymi 1:

- $V^1 = [0.6, 0.7, \texttt{'LONDON'}]$
- $V^2 = [0.4, 0.8, \texttt{'LONDONER'}]$

Obliczenia składowe:

- $\delta_1 = |0.6 - 0.4| = 0.2$
- $\delta_2 = |0.7 - 0.8| = 0.1$
- $G(c_3^1) = \{LO, ON, ND, DO, ON\} \rightarrow \{LO, ON, ND, DO\}$
- $G(c_3^2) = \{LO, ON, ND, DO, ON, NE, ER\} \rightarrow \{LO, ON, ND, DO, NE, ER\}$
- $J = \frac{|\{LO,ON,ND,DO\}|}{|\{LO,ON,ND,DO,NE,ER\}|} = \frac{2}{3} \approx 0.67$
- $\delta_3 = 1 - 0.67 = 0.33$

Wyniki dla różnych metryk:

- $D_{euklides} = \sqrt{0.2^2 + 0.1^2 + 0.33^2} \approx 0.4$
- $D_{manhattan} = 0.2 + 0.1 + 0.33 = 0.53$
- $D_{czebyszew} = \max(0.1, 0.2, 0.33) = 0.33$

5 Wyniki klasyfikacji dla różnych parametrów wejściowych

W niniejszej sekcji przedstawiono wstępne wyniki miary **Accuracy** dla próbnych klasyfikacji na ograniczonym zbiorze tekstów. Eksperymenty przeprowadzono zgodnie z założeniami projektu (punkty 3–8), obejmującymi dobór parametrów modelu, metryk odległości oraz podział danych.

5.1 Eksperyment 1: Wpływ parametru k oraz metryki odległości na Accuracy

W pierwszym eksperymencie analizowano wpływ liczby sąsiadów k na jakość klasyfikacji dla trzech metryk odległości:

- metryka euklidesowa,
- metryka Manhattan,
- metryka Czebyszewa.

Dla każdej metryki rozpoczęto od wartości $k = 1$, a następnie zwiększano k iteracyjnie. Proces zwiększania parametru k był kontynuowany do momentu, w którym przez trzy kolejne wartości k nie zaobserwowano poprawy wartości Accuracy. Następnie porównano uzyskane wyniki dla poszczególnych metryk.

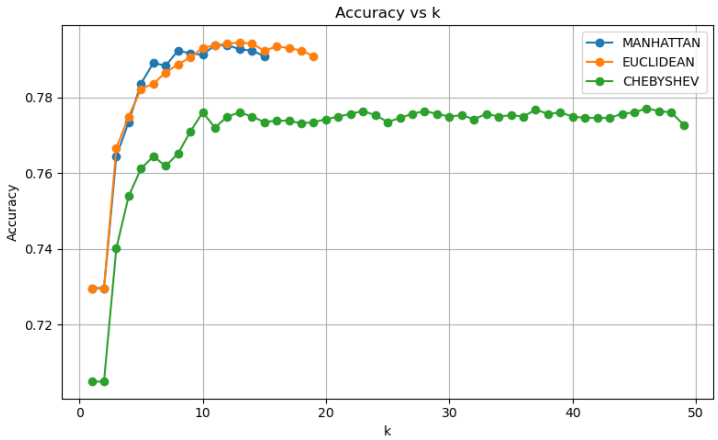

Rysunek 1: Accuracy w funkcji parametru k dla różnych metryk odległości

Najlepszy wynik uzyskany w eksperymencie 1 wyniósł:

- $k = 13$
- wielkość zbioru testowego = 20,00%
- metryka = euklidesowa
- liczba cech = 11
- Accuracy = 0,794555

5.2 Eksperyment 2: Wpływ wielkości zbioru testowego na Accuracy (metryka euklidesowa)

W drugim eksperymencie badano wpływ procentowego podziału danych na zbiór treningowy i testowy na skuteczność klasyfikacji. Wykorzystano metrykę euklidesową oraz stałą wartość parametru $k = 5$.

Testowano wszystkie proporcje zbioru testowego od 10% do 90% ze skokiem co 5%, tj.:

- 10%, 15%, 20%, ..., 85%, 90%.

Dla każdej konfiguracji obliczono Accuracy i przeanalizowano stabilność wyników.

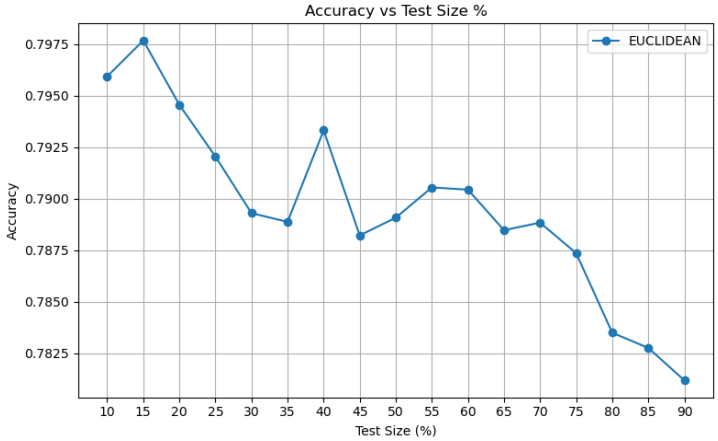

Rysunek 2: Wpływ wielkości zbioru testowego na (Accuracy) (metryka euklidesowa)

Najlepszy wynik w eksperymencie 2 uzyskano dla:

- $k = 13$
- wielkość zbioru testowego = 15%
- metryka = euklidesowa
- liczba cech = 11
- Accuracy = 0,797677

5.3 Eksperyment 3: Wpływ cech na Accuracy

W trzecim eksperymencie analizowano wpływ poszczególnych cech (feature'ów) na skuteczność klasyfikacji. Badanie polegało na:

- trenowaniu modelu z wykorzystaniem wszystkich cech,
- usuwaniu pojedynczych cech i obserwacji zmiany Accuracy.

Model trenowano dla $k = 13$, przy teście podzielonym na 15% danych oraz wykorzystaniu metryki EUCLIDEAN. Najlepsze uzyskane Accuracy wyniosło $0,802033$. Poniższa tabela przedstawia zestawy cech, które osiągnęły tę najwyższą wartość Accuracy:

1. alnumToOtherCharsRatio, charCount, longWordToOtherWordsRatio, properNounMidSentenceRatio, properNounFirst, rarestRepeatedWord, upperToAllCharsRatio, upperToLowerRatio, wordCount (9 cech)
2. alnumToOtherCharsRatio, charCount, longWordToOtherWordsRatio, properNounFirst, rarestRepeatedWord, upperToAllCharsRatio, upperToLowerRatio, wordCount (8 cech)
3. alnumToOtherCharsRatio, charCount, longWordToOtherWordsRatio, properNounMidSentenceRatio, rarestRepeatedWord, upperToAllCharsRatio,
   upperToLowerRatio, wordCount (8 cech)
4. alnumToOtherCharsRatio, charCount, longWordToOtherWordsRatio, properNounMidSentenceRatio, properNounFirst, rarestRepeatedWord, upperToLowerRatio, wordCount (8 cech)
5. alnumToOtherCharsRatio, charCount, longWordToOtherWordsRatio, properNounMidSentenceRatio, properNounFirst, rarestRepeatedWord, upperToAllCharsRatio, wordCount (8 cech)

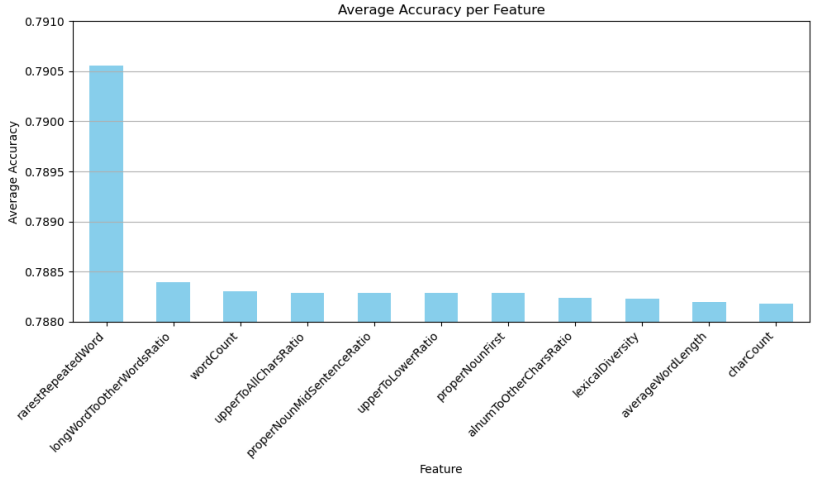

Rysunek 3: Średnie Accuracy uzyskane przy usuwaniu pojedynczych cech. Wykres pokazuje, które cechy mają największy wpływ na jakość klasyfikacji.

Najlepszy wynik został osiągnięty dla następujących parametrów:

- $k = 13$
- wielkość zbioru testowego = 15%
- metryka = euklidesowa
- liczba cech = 8
- zestaw cech:
  - alnumToOtherCharsRatio
  - charCount
  - longWordToOtherWordsRatio
  - properNounFirst
  - rarestRepeatedWord
  - upperToAllCharsRatio
  - upperToLowerRatio
  - wordCount

Tabela 2: Wyniki klasyfikacji dla najlepszego modelu

Klasa	**Precision**	**Recall**	**F1-score**
france	0.2500	0.0244	0.0444
japan	0.6250	0.1333	0.2198
uk	0.5000	0.2057	0.2915
canada	0.4219	0.2126	0.2827
usa	0.8271	0.9730	0.8941
west-germany	0.5000	0.0400	0.0741
Accuracy $\approx$ 0.8020			
Macro F1-score $\approx$ 0.3011			

Model osiąga wysoką dokładność ogólną, jednak wyniki dla poszczególnych klas są silnie zróżnicowane. Bardzo dobra skuteczność dla klasy USA znacząco zawyża wartość Accuracy, podczas gdy dla pozostałych klas model radzi sobie wyraźnie gorzej. Niska wartość macro F1-score wskazuje na brak równowagi w jakości klasyfikacji między klasami. Otrzymane wyniki sugerują, że model ma ograniczoną zdolność do poprawnego rozróżniania mniej reprezentowanych kategorii.

6 Dyskusja, wnioski, sprawozdanie końcowe

We wnioskach z badania skomentować wyłącznie wpływ parametrów i cech na jakość procesu klasyfikacji. Innymi słowy – wnioski to to, co wynika z przeprowadzonych obliczeń, a nie to co wiadomo z literatury. Znaczenie kolejnych eksperymentów wg punktów 2.-8. opisu projektu 1. Każdorazowo podane parametry, dla których przeprowadzana eksperyment. Wykresy (np. słupkowe) i tabele wyników obowiązkowe, dokładnie opisane w „captions" (tytułach), konieczny opis osi i jednostek wykresów oraz kolumn i wierszy tabel.

Ewentualne wyniki realizacji punktu 9. opisu Projektu 1., czyli „na ocenę 5.0" i ich porównanie do wyników z części obowiązkowej.Dokładne interpretacje uzyskanych wyników w zależności od parametrów klasyfikacji opisanych w punktach 3.-8 opisu Projektu 1. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: wykresów, tabel).
Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje poziom zrozumienia rozwiązywanego problemu.

** Możliwości kontynuacji prac w obszarze systemów rozpoznawania, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadań Tydzień 05 i Tydzień 06 wg Harmonogramu Zajęć na WIKAMP KSR.

7 Braki w realizacji projektu 1.

Wymienić wg opisu Projektu 1. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

[1] R. Tadeusiewicz: Rozpoznawanie obrazów, PWN, Warszawa, 1991.

[2] A. Niewiadomski, Methods for the Linguistic Summarization of Data: Applications of Fuzzy Sets and Their Extensions, Akademicka Oficyna Wydawnicza EXIT, Warszawa, 2008.

[3] David Lewis, *Reuters-21578 Text Categorization Collection*, UCI Machine Learning Repository, 1997. Dostępne online: `https://archive.ics.uci.edu/dataset/137/reuters+21578+text+categorization+collection`